

Tăng cường ảnh thiếu sáng bằng mạng Encoder–Decoder với hướng dẫn chiếu sáng (EDNIG) [1]

Le-Anh Tran^{id}, Chung Nguyen Tran^{id}, Ngoc-Luu Nguyen, Nhan Cach Dang^{id},
Jordi Carrabina^{id}, David Castells-Rufas^{id}, and Minh Son Nguyen^{id}

Biên soạn và trình bày lại bằng tiếng Việt từ nghiên cứu
“Low-Light Enhancement via Encoder-Decoder Network with
Illumination Guidance (EDNIG)” của thầy Trần Lê Anh^{id} và cộng
sự bởi học viên cao học:
Trần Quốc Bảo^{id} (2480101829)

Tóm tắt nội dung—Bài báo này giới thiệu một khung học sâu mới cho bài toán tăng cường ảnh thiếu sáng, được gọi là Encoder-Decoder Network with Illumination Guidance (EDNIG). Dựa trên kiến trúc U-Net, EDNIG tích hợp một bản đồ chiếu sáng được suy ra từ Bright Channel Prior (BCP) làm đầu vào hướng dẫn. Thông tin hướng dẫn chiếu sáng này giúp mạng tập trung vào các vùng thiếu sáng, từ đó điều hướng quá trình tăng cường ảnh một cách hiệu quả. Để tiếp tục cải thiện khả năng biểu diễn của mô hình, mô-đun Spatial Pyramid Pooling (SPP) được tích hợp nhằm trích xuất các đặc trưng ngữ cảnh đa tỉ lệ, cho phép xử lý tốt hơn trong các điều kiện chiếu sáng đa dạng. Ngoài ra, hàm kích hoạt Swish được sử dụng nhằm đảm bảo quá trình lan truyền gradient mượt mà hơn trong quá trình huấn luyện. EDNIG được tối ưu trong khuôn khổ Generative Adversarial Network (GAN) thông qua hàm mất mát tổng hợp kết hợp giữa adversarial loss, sai số bình phương trung bình theo điểm ảnh (MSE) và perceptual loss. Kết quả thực nghiệm cho thấy EDNIG đạt hiệu năng cạnh tranh so với các phương pháp tiên tiến hiện nay cả về chỉ số định lượng lẫn chất lượng thị giác, đồng thời vẫn duy trì độ phức tạp mô hình thấp, cho thấy tính phù hợp đối với các ứng dụng thực tế. Mã nguồn của nghiên cứu được công bố tại <https://github.com/tranleanh/ednig>.


Từ khóa—Tăng cường ảnh thiếu sáng, U-Net, mạng encoder-decoder, Generative Adversarial Network (GAN), hướng dẫn chiếu sáng. *English: Low-light enhancement, U-Net, encoder-decoder network, generative adversarial network, illumination guidance.*

I. GIỚI THIỆU

Cải thiện chất lượng hình ảnh trong điều kiện thiếu sáng vẫn là một thách thức quan trọng trong lĩnh vực thị giác máy tính, với nhiều ứng dụng trải dài từ chụp ảnh ban đêm, giám sát, xe tự hành cho đến ảnh y khoa. Các ảnh được chụp trong điều kiện thiếu sáng thường gặp phải các vấn đề như kém rõ nét, độ tương phản thấp và nhiễu cao, làm suy giảm cả chất lượng cảm nhận của con người lẫn hiệu quả của các tác vụ xử lý phía sau như phát hiện và nhận dạng đối tượng. Các phương pháp truyền thống cho bài toán này, bao gồm cân bằng biểu đồ tần suất [2] và hiệu chỉnh gamma [3], thường chỉ mang lại cải thiện hạn chế, đồng thời dễ tạo ra nhiễu giả hoặc không thể khôi phục được các chi tiết nhỏ.

Trong những năm gần đây, các kỹ thuật học sâu như mạng nơ-ron tích chập (CNN) và mạng đối kháng sinh dữ liệu (GAN) [4] đã nổi lên như những công cụ mạnh mẽ cho xử lý ảnh, tận dụng dữ liệu quy mô lớn cùng các kiến trúc Mã hóa–Giải mã (Encoder-Decoder) tiên tiến cho các tác vụ ánh xạ ảnh đầu vào sang ảnh đầu ra để đạt được hiệu quả ấn tượng [5]–[7]. Một ví dụ tiêu biểu là Encoder–Decoder Network with Guided Transmission Map (EDN-GTM) [8]–[10], Mạng Mã hóa–Giải mã với Bản đồ Truyền ánh sáng Hướng dẫn, vốn được đề xuất cho bài toán khử sương mù từ một ảnh đơn. Trong đó, truyền dẫn ánh sáng ở đây là mức độ ánh sáng truyền xuyên qua môi trường đến camera, xa thì truyền dẫn thấp, gần thì truyền dẫn cao. EDN-GTM tích hợp bản đồ truyền tải được suy ra từ Dark Channel Prior (DCP) [11] vào kiến trúc U-Net [5], từ đó hướng dẫn mạng thực hiện quá trình loại bỏ sương mù hiệu quả. Mặc dù EDN-GTM cho kết quả rất tốt trong bài toán khử sương mù, việc phụ thuộc vào bản đồ truyền ánh sáng – vốn được thiết kế riêng cho hiện tượng tán xạ khí quyển – khiến phương pháp này khó áp dụng trực tiếp cho bài toán cải thiện ảnh thiếu sáng, nơi phân bố chiếu sáng đóng vai trò quan trọng hơn. Tuy nhiên, kiến trúc tổng thể của EDN-GTM vẫn cho thấy nhiều tiềm năng đầy hứa hẹn đối với các tác vụ phục hồi ảnh nhờ khả năng trích xuất đặc trưng đa tỉ lệ thông qua Spatial Pyramid Pooling (SPP) [10].

Lấy cảm hứng từ sự thành công của EDN-GTM trong phục hồi ảnh, nghiên cứu này đề xuất một hướng thích nghi mới của khung EDN-GTM cho bài toán cải thiện chất lượng hình ảnh trong điều kiện thiếu sáng. Cụ thể, bản đồ truyền dẫn ánh sáng được chúng tôi thay thế bằng bản đồ chiếu sáng (illumination map), suy ra từ Bright Channel Prior (BCP) [12], từ đó hình thành mô hình Encoder-Decoder Network with Illumination Guidance (EDNIG). Bản đồ chiếu sáng, vốn ước lượng phân bố cường độ ánh sáng trong không gian ảnh, đóng vai trò như một cơ chế hướng dẫn tự nhiên cho bài toán này. Bằng cách đưa đồng thời ảnh RGB thiếu sáng và bản đồ chiếu sáng vào mạng encoder–decoder, EDNIG học cách cải thiện khả năng hiển thị trong khi vẫn bảo toàn cấu trúc ảnh và giảm thiểu nhiễu. Việc chuyển trọng tâm từ truyền dẫn ánh sáng sang chiếu sáng không chỉ góp phần nâng cao hiệu quả trong việc cải thiện chất lượng ảnh thiếu sáng mà còn cung cấp một khung linh hoạt, mở ra khả năng thích nghi cho các bài toán phục hồi ảnh liên quan khác. Tóm lại, các đóng góp chính của nghiên cứu bao gồm: 1) đề xuất cơ chế sử dụng illumination



Hình 1: Khung EDNIG.

map để hướng dẫn mô hình học sâu; 2) thiết kế kiến trúc mạng phù hợp cho phục hồi ảnh thiếu sáng; và 3) đánh giá thực nghiệm trên nhiều tình huống khác nhau, cho thấy mô hình đạt hiệu quả cao cả về chất lượng thị giác lẫn các chỉ số định lượng trong khi vẫn duy trì độ phức tạp thấp.

Phần còn lại của bài báo này được trình bày như sau: Mục II mô tả ngắn gọn các công trình nghiên cứu liên quan. Khung đề xuất được trình bày chi tiết trong Phần III. Kết quả thực nghiệm được trình bày trong Phần IV. Phần V kết luận bài báo.


II. CÔNG TRÌNH NGHIÊN CỨU LIÊN QUAN

Các phương pháp tăng cường ảnh thiếu sáng ban đầu chủ yếu dựa trên các kỹ thuật xử lý ảnh truyền thống, chẳng hạn như cân bằng biểu đồ tần suất và các biến thể của nó, nhằm tái phân bố giá trị độ sáng của các điểm ảnh, trên biểu đồ histogram, để cải thiện độ tương phản [2], [13]. Mặc dù có chi phí tính toán thấp, các phương pháp này thường làm khuếch đại nhiễu và không thể khôi phục chi tiết trong các vùng thiếu sáng nghiêm trọng. Các phương pháp dựa trên Retinex, được xây dựng dựa trên lý thuyết cảm nhận màu sắc của con người, phân rã ảnh thành các thành phần phản xạ và chiếu sáng để điều chỉnh ánh sáng [14]. Single-Scale Retinex (SSR) [15] và Multi-Scale Retinex (MSR) [16] cho thấy nhiều tiềm năng, tuy nhiên hiệu quả của chúng phụ thuộc mạnh vào quá trình tinh chỉnh tham số và gặp khó khăn trong các cảnh phức tạp. Các phương pháp tối ưu hóa như LIME [17] ước lượng illumination map bằng các prior được thiết kế thủ công và tinh chỉnh thông qua điều chỉnh. Mặc dù đạt hiệu quả trong một số trường hợp, các phương pháp này thiếu khả năng tổng quát hóa cần thiết đối với nhiều điều kiện thiếu sáng khác nhau.

Hiện nay, học sâu đã tạo ra bước chuyển lớn trong bài toán tăng cường ảnh thiếu sáng thông qua khả năng học đặc trưng dựa trên dữ liệu, trong đó các kiến trúc encoder-decoder như U-Net [5] cho thấy hiệu quả vượt trội. Retinex-Net [18] kết hợp lý thuyết Retinex [14] với học sâu bằng cách huấn luyện riêng biệt các mạng cho quá trình phân rã và điều chỉnh chiếu sáng. GLADNet [19] khai thác thông tin tiên nghiệm toàn cục của

illumination nhằm tái tạo chi tiết, trong khi KinD [20] phân rã ảnh thành thành phần phản xạ và illumination, đồng thời sử dụng các mạng chuyên biệt cho phục hồi chi tiết và điều chỉnh độ sáng. KinD++ [21] tiếp tục cải tiến KinD bằng cơ chế ước lượng illumination tốt hơn và giảm nhiễu hiệu quả hơn. Uformer [22] giới thiệu hướng tiếp cận dựa trên transformer nhằm cải thiện khả năng khôi phục chi tiết. WeatherDiff [23] giải quyết bài toán tăng cường ảnh thiếu sáng trong điều kiện thời tiết bất lợi thông qua quá trình diffusion khử nhiễu không phụ thuộc kích thước ảnh. PQP [24] sử dụng prior bất biến theo illumination, được dẫn dắt bởi lý thuyết truyền ánh sáng vật lý, nhằm phục hồi ảnh thông qua khung prior-to-image có khả năng huấn luyện. Các phương pháp này đạt được khả năng tăng cường ảnh chân thực và duy trì cấu trúc tốt, cho thấy tiềm năng lớn của mạng nơ-ron trong lĩnh vực này.

Các mô hình học sâu có hướng dẫn (guided deep learning), vốn tích hợp các prior đặc thù miền vào mạng nơ-ron, tạo nên một hướng tiếp cận trung gian hiệu quả giữa các phương pháp truyền thống và các phương pháp hoàn toàn dựa trên dữ liệu. Trong bài toán phục hồi ảnh, EDN-GTM [10] là một ví dụ tiêu biểu khi sử dụng transmission map được ước lượng thông qua Dark Channel Prior (DCP) [11] nhằm hướng dẫn mạng dựa trên U-Net thực hiện khử sương mù hiệu quả. Transmission map đóng vai trò như thông tin phụ trợ liên quan đến độ sâu, cho phép mạng thích nghi với các mức độ sương mù khác nhau. Kế thừa thành công của EDN-GTM, nghiên cứu này thay thế transmission map bằng illumination map phù hợp hơn với phân bố ánh sáng trong bài toán thiếu sáng. Mặc dù đã tồn tại một số mô hình có hướng dẫn dựa trên illumination, phương pháp EDNIG được đề xuất nổi bật nhờ việc kết hợp các thành phần kiến trúc đơn giản nhưng hiệu quả cùng hàm mất mát lai, lấy cảm hứng từ thiết kế của EDN-GTM. Điều này giúp EDNIG trở thành một đóng góp mới tại giao điểm giữa guided deep learning và tăng cường ảnh thiếu sáng, hướng tới khả năng phục hồi ảnh bền vững và chất lượng cao.



Hình 2: So sánh trực quan điển hình các phương pháp khác nhau trên tập dữ liệu xác thực LOL.

III. PHƯƠNG PHÁP NGHIÊN CỨU

A. Trích Xuất Thông Tin Hướng Dẫn Chiếu Sáng

Để trích xuất bản đồ hướng dẫn chiếu sáng M , nghiên cứu này sử dụng Bright Channel Prior (BCP) [12], một tiên đề thống kê giả định rằng trong các ảnh tự nhiên được chiếu sáng tốt, ít nhất một kênh màu RGB trong một vùng cục bộ sẽ có cường độ sáng cao. Cụ thể, với ảnh đầu vào thiếu sáng I , trước tiên một bản đồ chiếu sáng ban đầu $\tilde{M}$ được ước lượng bằng cách lấy giá trị cường độ lớn nhất trên các kênh $\{R, G, B\}$ tại mỗi vùng cục bộ:

$$\tilde{M}(x) = \max_{y \in \alpha(x)} \max_{c \in \{R, G, B\}} I_c(y), \quad (1)$$

trong đó $I_c(\cdot)$ là cường độ của kênh màu c tại điểm ảnh y trong vùng lân cận cục bộ $\alpha(\cdot)$ có tâm tại x . Để tinh chỉnh $\tilde{M}$ và giảm nhiễu hoặc sự không nhất quán, bộ lọc có hướng dẫn được áp dụng [25], tạo ra bản đồ chiếu sáng đã được làm mượt M . Bộ lọc định hướng bảo toàn các biên phù hợp với ảnh đầu vào đồng thời hạn chế các nhiễu giả, giúp M trở thành một tín hiệu hướng dẫn ổn định cho mạng. Bản đồ chiếu sáng thu được sau đó được kết hợp với I , tạo thành đầu vào bốn kênh $\{R, G, B, M\}$ cho mạng..

B. Kiến Trúc Mạng

Hình 1 minh họa kiến trúc của khung phương pháp được đề xuất. Generator của EDNIG được xây dựng dựa trên kiến trúc EDN-GTM, đồng thời được điều chỉnh cho phù hợp với bài toán tăng cường ảnh thiếu sáng. Để cải thiện hiệu quả tính toán, số lượng kênh trong lớp đầu tiên được giảm từ 64 xuống còn 12. Sau mỗi bước giảm kích thước đặc trưng, số lượng kênh được tăng gấp đôi. Nhờ đó, số lượng tham số của mô hình giảm xuống còn khoảng 1.74 triệu, thấp hơn đáng kể so với 33.26 triệu tham số của EDN-GTM. Như minh họa trong Hình 1, EDNIG sử dụng kiến trúc encoder-decoder trong khung GAN [4]. Encoder bao gồm năm khối tích chập để trích xuất đặc trưng từ đầu vào bốn kênh. Mỗi khối bao gồm ba lớp tích chập $Conv3 \times 3$ với bước nhảy bằng 1 và hàm kích hoạt Swish. So với ReLU và LeakyReLU, Swish cung cấp tính phi tuyến mượt hơn, giúp cải thiện quá trình lan truyền gradient và

cho phép mô hình học các đặc trưng phức tạp hiệu quả hơn. Phép gộp tối đa kích thước 2×2 với bước nhảy bằng 2 được sử dụng bốn lần nhằm giảm kích thước không gian của bản đồ đặc trưng, tạo ra các mức đặc trưng có kích thước bằng $1/2$, $1/4$, $1/8$ và $1/16$ so với ảnh đầu vào. Tại bottleneck, mô-đun Spatial Pyramid Pooling (SPP) sử dụng các hạt nhân có kích thước 5×5 , 9×9 và 13×13 nhằm trích xuất các đặc trưng ngữ cảnh đa tỉ lệ. Cụ thể, hạt nhân nhỏ hơn (5×5) tập trung vào các chi tiết cục bộ tinh vi, hạt nhân trung bình (9×9) cân bằng giữa thông tin cục bộ và toàn cục, trong khi hạt nhân lớn hơn (13×13) nắm bắt ngữ cảnh rộng hơn. Thiết kế đa tỉ lệ này giúp cải thiện khả năng xử lý các đặc trưng ở nhiều mức tỉ lệ khác nhau. Decoder sau đó khôi phục độ phân giải ban đầu của ảnh thông qua bốn bước upsampling. Tại mỗi bước, các feature map từ encoder được kết hợp với feature map tương ứng trong decoder thông qua skip connection. Cuối cùng, lớp $Conv1 \times 1$ kết hợp với hàm kích hoạt Tanh được sử dụng để tạo ra ảnh tăng cường đầu ra. Critic sử dụng cấu hình tương tự EDN-GTM [10], đồng thời áp dụng chiến lược giảm số lượng kênh tương tự như trong generator.

C. Hàm Mất Mát

Để huấn luyện generator (EDNIG), nghiên cứu sử dụng hàm mất mát tổng hợp bao gồm adversarial loss, MSE loss và perceptual loss nhằm đồng thời tối ưu tính chân thực, độ chính xác theo điểm ảnh và chất lượng tri giác của ảnh đầu ra. Adversarial loss $\mathcal{L}_{Adv}$ được xác định như sau [26]:

$$\mathcal{L}_{Adv} = \frac{1}{B} \sum_{i=1}^B -C(G(I)), \quad (2)$$

trong đó B , $C(\cdot)$, $G(\cdot)$ và I lần lượt biểu diễn batch size, critic, generator và ảnh thiếu sáng đầu vào. MSE loss $\mathcal{L}_{MSE}$ được định nghĩa như sau:

$$\mathcal{L}_{MSE} = \frac{1}{N} \sum_{i=1}^N (G_i(z) - Y_i)^2, \quad (3)$$

Bảng I: So sánh định lượng trên bộ dữ liệu LOL. Các giá trị **in đậm** và gạch chân lần lượt biểu thị kết quả **tốt nhất** và **tốt thứ hai**.

Phương pháp	Năm	PSNR↑	SSIM↑	#Param(M)
Retinex-Net [18]	2018	16.774	0.5594	0.838
GLADNet [19]	2018	19.718	0.7035	1.128
KinD [20]	2019	20.726	0.8103	8.540
Zero-DCE [28]	2020	14.870	0.6600	0.079
Kind++ [21]	2021	21.300	0.8226	8.275
DRBN [29]	2021	20.130	<u>0.8300</u>	5.270
Uformer [22]	2022	18.547	0.7212	5.290
Restomer [30]	2022	20.410	0.8060	26.130
WeatherDiff [23]	2023	17.913	0.8110	82.960
IR-SDE [31]	2023	20.450	0.7870	34.200
IDR [32]	2023	21.340	0.8260	15.340
PQP [24]	2024	20.310	0.8080	0.327
EDNIG (ours)		21.512	0.8313	1.737

trong đó N là số lượng điểm ảnh đầu vào và Y là ảnh thực tế. Perceptual loss $\mathcal{L}_{Per}$ để tối ưu hóa sự tương đồng về nhận thức được tính như sau [27]:

$$\mathcal{L}_{Per} = \frac{1}{M} \sum_{i=1}^M (\phi_i(G(I)) - \phi_i(Y))^2, \quad (4)$$

trong đó M chỉ số lượng phần tử trong bản đồ đặc trưng ϕ sau lớp $Conv3-3$ của mô hình VGG16, và ϕ_i biểu thị giá trị kích hoạt thứ i của ϕ .

Bằng cách kết hợp các hàm mất mát trên, hàm mất mát tổng quát $\mathcal{L}_{Gen}$ dùng để tối ưu generator được xác định như sau:

$$\mathcal{L}_{Gen} = \lambda_1 \mathcal{L}_{Adv} + \lambda_2 \mathcal{L}_{MSE} + \lambda_3 \mathcal{L}_{Per}, \quad (5)$$

trong khi đó, hàm mất mát $\mathcal{L}_{Cri}$ dùng để huấn luyện critic được xác định bởi:

$$\mathcal{L}_{Cri} = \lambda_4 \frac{1}{B} \sum_{i=1}^B (C(Y) - C(G(I))). \quad (6)$$

Tương tự [9], các hệ số được thiết lập là $\lambda_1 = 100$, $\lambda_2 = 100$, $\lambda_3 = 100$ và $\lambda_4 = 1$.

IV. THỰC NGHIỆM

A. Thiết lập thực nghiệm

Các thực nghiệm được thực hiện trên môi trường Linux với GPU GeForce GTX TITAN X và CPU Intel(R) Xeon(R) Gold 6134 @3.20 GHz. Khung phương pháp đề xuất được triển khai bằng thư viện Tensorflow. Bộ dữ liệu được sử dụng là LOL (Low-Light) dataset [18], bao gồm 500 cặp ảnh thiếu sáng/ánh sáng bình thường, trong đó 485 cặp được dùng cho huấn luyện và 15 cặp được dùng cho kiểm thử. Mạng được tối ưu bằng bộ tối ưu Adam [33] với batch size bằng 1 và learning rate là 10^{-4} , giảm dần về 0 sau 200 epochs. Kích thước đầu vào của mạng là 512×512 . Các phương pháp tăng cường dữ liệu, bao gồm random flip và random crop, được sử dụng nhằm cải thiện quá trình học. Hiệu năng định lượng trên dữ liệu có cặp được đánh giá bằng PSNR và SSIM, trong khi dữ liệu tự nhiên được đánh giá bằng NIQE [34] và BRISQUE [35]. Giá trị PSNR và SSIM cao hơn cho thấy hiệu năng tốt

Bảng II: So sánh định lượng trên dữ liệu ảnh thực tế. Các giá trị **in đậm** và gạch chân lần lượt biểu thị kết quả **tốt nhất** và **tốt thứ hai**.

Phương pháp	Năm	NIQE↓	BRISQUE↓	#Param(M)
Retinex-Net [18]	2018	15.731	21.994	0.838
GLADNet [19]	2018	13.734	23.372	1.128
KinD [20]	2019	15.041	24.738	8.540
Kind++ [21]	2021	14.265	21.246	8.275
PQP [24]	2024	13.253	20.309	0.327
EDNIG (ours)		<u>13.443</u>	<u>20.515</u>	1.737

hơn, trong khi giá trị NIQE và BRISQUE thấp hơn phản ánh kết quả tốt hơn. Mặt khác, độ phức tạp tính toán được đánh giá dựa trên số lượng tham số (#Params).

B. Phân Tích Định Lượng

Hiệu năng định lượng của mô hình EDNIG được đề xuất được đánh giá trên bộ dữ liệu LOL và so sánh với nhiều phương pháp tiên tiến hiện nay. Như được trình bày trong Bảng I, EDNIG đạt PSNR bằng 21.512 và SSIM bằng 0.8313, vượt qua tất cả các phương pháp so sánh ở cả hai chỉ số. So với các phương pháp trước đây như Retinex-Net, GLADNet và KinD, EDNIG cho thấy sự cải thiện đáng kể. Các phương pháp gần đây hơn như Kind++ và DRBN cũng bị vượt qua bởi EDNIG. Hơn nữa, khi so sánh với các kỹ thuật tiên tiến như IR-SDE, Restomer và IDR, EDNIG liên tục đạt giá trị PSNR và SSIM cao hơn, xác nhận hiệu năng vượt trội của mô hình.


Về độ phức tạp của mô hình, EDNIG duy trì kiến trúc gọn nhẹ với 1.737M tham số, tương đương với các phương pháp như Retinex-Net (0.838M) và GLADNet (1.128M), đồng thời nhỏ gọn hơn đáng kể so với các mô hình hiện đại như WeatherDiff (82.96M) và IR-SDE (34.20M). Sự cân bằng giữa hiệu năng cao và độ phức tạp tính toán thấp giúp EDNIG đặc biệt phù hợp với các ứng dụng thực tế có giới hạn tài nguyên tính toán.

Ngoài ra, Bảng II trình bày so sánh hiệu năng định lượng trên tập gồm 10 ảnh thực tế tiêu chuẩn. Như được báo cáo trong Bảng II, PQP và EDNIG đạt kết quả tốt nhất. PQP đạt kết quả cao nhất với NIQE bằng 13.253 và BRISQUE bằng 20.309, trong khi EDNIG theo sát với NIQE bằng 13.443 và BRISQUE bằng 20.515, xếp thứ hai ở cả hai chỉ số.

Nhìn chung, các kết quả định lượng trên bộ dữ liệu LOL và dữ liệu thực tế cho thấy EDNIG đạt được sự cân bằng tốt giữa chất lượng ảnh và hiệu quả tính toán, vượt trội hơn phần lớn các phương pháp tiên tiến hiện nay về các chỉ số định lượng trong khi vẫn duy trì kích thước mô hình tương đối nhỏ gọn.

C. Phân Tích Định Tính

Các so sánh định tính trên tập kiểm thử LOL và dữ liệu ảnh thực tế được trình bày lần lượt trong Hình 2 và Hình 3. Việc so sánh bao gồm nhiều phương pháp tiên tiến hiện nay như GLADNet, KinD, Kind++, PQP, Retinex-Net và phương pháp EDNIG được đề xuất. Dữ liệu tham chiếu (Ground truth – GT) được cung cấp trong bộ dữ liệu LOL nhằm làm tham chiếu cho quá trình phục hồi lý tưởng.



Hình 3: So sánh trực quan điển hình các phương pháp khác nhau trên dữ liệu hình ảnh thực tế.

Như được minh họa trong Hình 2, GLADNet và KinD tạo ra một mức độ tăng cường độ sáng nhất định nhưng thường gặp vấn đề về biến dạng màu sắc và khuếch đại nhiễu. KinD++ cải thiện KinD bằng khả năng bảo toàn cấu trúc tốt hơn, trong khi PQP tăng cường độ tương phản nhưng tạo ra các thay đổi tông màu thiếu tự nhiên. Ngược lại, EDNIG phục hồi hiệu quả cả chi tiết ánh sáng lẫn chi tiết cấu trúc, đồng thời duy trì tính nhất quán màu sắc và giảm các nhiễu giả cũng như nhiễu không mong muốn.

Hình 3 trình bày các so sánh định tính trên dữ liệu ảnh thực tế điển hình. Các ảnh này không có ground truth, do đó chất lượng tri giác cần được đánh giá chủ quan. Như thể hiện trong Hình 3, Retinex-Net tạo ra biến dạng màu sắc đáng kể và các nhiễu giả thiếu tự nhiên, trong khi GLADNet cho kết quả điều chỉnh độ sáng không nhất quán. KinD và KinD++ cải thiện khả năng hiển thị tổng thể nhưng có xu hướng khuếch đại độ bão hòa và các nhiễu ở biên. PQP mang lại kết quả cạnh tranh nhưng đôi khi làm thay đổi về tự nhiên của cảnh ảnh. Trái lại, EDNIG liên tục tạo ra các kết quả tăng cường có chất lượng thị giác tốt, duy trì khả năng tái tạo màu sắc tự nhiên, bảo toàn chi tiết tinh vi và tránh hiện tượng tăng sáng quá mức.

Nhìn chung, phân tích định tính cho thấy EDNIG có tính cạnh tranh cao so với các phương pháp hiện có trong bài toán tăng cường ảnh thiếu sáng bằng cách đạt được sự cân bằng vượt trội giữa hiệu chỉnh độ sáng, khử nhiễu và bảo toàn màu sắc. Các kết quả này cho thấy tiềm năng của EDNIG trong các ứng dụng thực tế.

D. Phân Tích Thời Gian Thực Thi

Mặc dù #Params phần nào phản ánh độ phức tạp của mô hình, chỉ số này vẫn chưa đủ để đánh giá toàn diện các yếu tố liên quan đến suy luận như truy cập bộ nhớ, mức độ song song và đặc tính nền tảng phần cứng [36]. Do đó, nghiên cứu tiến hành thêm so sánh về thời gian thực thi giữa nhiều phương pháp hiện đại.

Bảng III: Thời gian thực thi trung bình (tính bằng giây) của các phương pháp khác nhau. Các giá trị **in đậm** và gạch chân lần lượt biểu thị kết quả **tốt nhất** và **tốt thứ hai**.

Phương pháp	Framework	Thời gian chạy (giây)
Retinex-Net [18]	TensorFlow	0.121
GLADNet [19]	TensorFlow	0.035
KinD [20]	TensorFlow	0.192
KinD++ [21]	TensorFlow	0.189
PQP [24]	PyTorch	3.254
EDNIG (ours)	TensorFlow	<u>0.042</u>

Table III compares the average runtime (in seconds) of different methods on the LOL validation set. As summarized in Table III, GLADNet achieves the fastest runtime at 0.035 seconds, followed by the proposed EDNIG at 0.042 seconds, both built based on TensorFlow. Retinex-Net, KinD, and KinD++ record runtimes of 0.121, 0.192, and 0.189 seconds, respectively, also on TensorFlow, indicating moderate efficiency. PQP, implemented in PyTorch, is the slowest at 3.254 seconds, likely due to the framework's architectural complexity. The results highlight GLADNet and EDNIG as the most efficient, with EDNIG offering a competitive runtime while maintaining strong quality metrics.

Bảng III so sánh thời gian chạy trung bình (tính bằng giây) của các phương pháp khác nhau trên tập kiểm thử LOL. Như được trình bày trong Bảng III, GLADNet đạt thời gian thực thi nhanh nhất với 0.035 giây, tiếp theo là EDNIG với 0.042 giây, cả hai đều được xây dựng trên TensorFlow. Retinex-Net, KinD và KinD++ đạt thời gian lần lượt là 0.121, 0.192 và 0.189 giây, cũng trên TensorFlow, cho thấy mức hiệu quả trung bình. PQP, được triển khai bằng PyTorch, có thời gian chậm nhất với 3.254 giây, có thể do độ phức tạp kiến trúc của framework. Các kết quả cho thấy GLADNet và EDNIG là hai phương pháp hiệu quả nhất, trong đó EDNIG đạt thời gian thực thi cạnh tranh

trong khi vẫn duy trì các chỉ số chất lượng cao.

E. Thảo luận và Phân tích

Mặc dù EDNIG được phát triển dựa trên kiến trúc EDN-GTM vốn được đề xuất cho bài toán khử sương mù ảnh, kết quả nghiên cứu cho thấy cơ chế guidance hoàn toàn có thể được thích nghi hiệu quả cho bài toán tăng cường ảnh thiếu sáng thông qua việc thay thế transmission map bằng illumination map. Đây là một điểm khác biệt quan trọng về mặt bản chất bài toán. Trong bài toán dehazing, transmission map chủ yếu phản ánh mức độ truyền ánh sáng và ảnh hưởng của hiện tượng tán xạ khí quyển theo độ sâu cảnh ảnh. Ngược lại, trong bài toán low-light enhancement, vấn đề cốt lõi nằm ở sự phân bố không đồng đều của ánh sáng trong không gian ảnh. Vì vậy, illumination map phù hợp hơn trong vai trò tín hiệu hướng dẫn cho quá trình phục hồi ảnh thiếu sáng.

Thông qua việc sử dụng illumination guidance, EDNIG có khả năng tập trung mạnh hơn vào các vùng thiếu sáng nghiêm trọng mà không làm thay đổi quá mức các vùng đã được chiếu sáng đầy đủ. Điều này góp phần cải thiện khả năng bảo toàn màu sắc tự nhiên và cấu trúc ảnh sau tăng cường. Ngoài ra, việc kết hợp illumination map trực tiếp với ảnh RGB đầu vào dưới dạng dữ liệu bốn kênh cũng giúp mô hình khai thác đồng thời cả thông tin nội dung ảnh và thông tin phân bố ánh sáng, từ đó hỗ trợ quá trình học đặc trưng hiệu quả hơn.

Một điểm đáng chú ý khác của EDNIG là khả năng duy trì sự cân bằng giữa chất lượng phục hồi và độ phức tạp tính toán. Trong khi nhiều phương pháp hiện đại dựa trên transformer hoặc diffusion model thường yêu cầu số lượng tham số rất lớn cùng chi phí tính toán cao, EDNIG chỉ sử dụng khoảng 1.74M tham số nhưng vẫn đạt kết quả cạnh tranh trên các chỉ số PSNR và SSIM. Điều này cho thấy rằng việc khai thác prior phù hợp kết hợp với thiết kế kiến trúc encoder-decoder hiệu quả vẫn có thể mang lại hiệu năng cao mà không nhất thiết phải sử dụng các mô hình quá lớn. Đây là một ưu điểm quan trọng đối với các ứng dụng thực tế có giới hạn về tài nguyên phần cứng hoặc yêu cầu xử lý thời gian thực.

Bên cạnh đó, mô-đun Spatial Pyramid Pooling (SPP) cũng đóng vai trò đáng kể trong việc cải thiện khả năng biểu diễn đặc trưng của mô hình. Thông qua việc sử dụng nhiều kích thước pooling kernel khác nhau, EDNIG có thể đồng thời khai thác các đặc trưng cục bộ và ngữ cảnh toàn cục. Điều này đặc biệt hữu ích trong các cảnh thiếu sáng phức tạp, nơi các vùng tối có thể xuất hiện ở nhiều quy mô khác nhau. Việc kết hợp thông tin đa tỉ lệ giúp mô hình phục hồi chi tiết tốt hơn đồng thời hạn chế hiện tượng mất cấu trúc hoặc tăng sáng thiếu tự nhiên.

Tuy nhiên, phương pháp được đề xuất vẫn tồn tại một số hạn chế nhất định. Do illumination map được xây dựng dựa trên Bright Channel Prior (BCP), chất lượng của tín hiệu guidance phụ thuộc đáng kể vào giả định rằng trong mỗi vùng cục bộ sẽ tồn tại ít nhất một điểm ảnh có cường độ sáng cao. Giả định này có thể không còn phù hợp trong các cảnh cực tối, môi trường có nhiều mảnh hoặc các trường hợp xuất hiện sai lệch màu sắc nghiêm trọng. Trong các tình huống như vậy, illumination map được ước lượng có thể thiếu chính xác, dẫn

đến hiện tượng tăng sáng không đồng đều hoặc khuếch đại nhiễu tại các vùng tối sâu.

Ngoài ra, mặc dù EDNIG cho thấy khả năng tổng quát hóa tốt trên bộ dữ liệu LOL và dữ liệu ảnh thực tế, mô hình hiện vẫn chưa được đánh giá trên các tình huống phục hồi phức tạp hơn như ảnh thiếu sáng kết hợp sương mù, mưa hoặc nhiễu cảm biến mạnh. Đây là những điều kiện thường gặp trong các ứng dụng thực tế như giám sát giao thông, camera an ninh ban đêm hoặc xe tự hành. Do đó, trong tương lai, việc mở rộng framework theo hướng kết hợp attention mechanism, learned illumination estimation hoặc semantic guidance từ các mô hình thị giác-ngôn ngữ có thể giúp cải thiện thêm độ bền vững và khả năng thích nghi của hệ thống trong nhiều điều kiện môi trường khác nhau.

V. KẾT LUẬN

Trong nghiên cứu này, chúng tôi trình bày EDNIG, một khung học sâu cho bài toán tăng cường ảnh thiếu sáng, được xây dựng bằng cách cải tiến kiến trúc U-Net thông qua việc tích hợp bản đồ chiếu sáng được suy ra từ BCP. Thiết kế này giúp mô hình tập trung hiệu quả hơn vào các vùng thiếu sáng, trong khi mô-đun SPP cho phép trích xuất đặc trưng đa tỉ lệ mạnh mẽ nhằm xử lý các điều kiện chiếu sáng đa dạng. Được tối ưu trong khung GAN thông qua hàm mất mát tổng hợp bao gồm adversarial loss, mean squared error loss và perceptual loss, EDNIG liên tục tạo ra các kết quả cạnh tranh so với nhiều phương pháp tiên tiến hiện nay cả về chỉ số định lượng lẫn chất lượng thị giác. Các đánh giá trên bộ dữ liệu chuẩn và ảnh thiếu sáng thực tế cho thấy mô hình EDNIG được đề xuất có khả năng tổng quát hóa tốt và tính ứng dụng thực tiễn cao. Trong tương lai, nghiên cứu sẽ tập trung vào việc cải thiện quá trình ước lượng illumination, tích hợp các cơ chế attention và mở rộng khung phương pháp cho tăng cường video thời gian thực cũng như các bộ dữ liệu đa dạng hơn nhằm tiếp tục nâng cao hiệu quả xử lý ảnh thiếu sáng.

TÀI LIỆU

- [1] L.-A. Tran, C. N. Tran, N.-L. Nguyen, N. C. Dang, J. Carrabina, D. Castells-Rufas, and M. S. Nguyen, "Low-light enhancement via encoder-decoder network with illumination guidance," *arXiv preprint arXiv:2507.13360*, 2025. **1**
- [2] J. R. Jebadass and P. Balasubramaniam, "Low light enhancement algorithm for color images using intuitionistic fuzzy sets with histogram equalization," *Multimedia Tools and Applications*, vol. 81, no. 6, pp. 8093–8106, 2022. **1, 2**
- [3] I. Jeong and C. Lee, "An optimization-based approach to gamma correction parameter estimation for low-light image enhancement," *Multimedia Tools and Applications*, vol. 80, pp. 18 027–18 042, 2021. **1**
- [4] I. J. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio, "Generative adversarial nets," *Advances in neural information processing systems*, vol. 27, 2014. **1, 3**
- [5] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *Medical image computing and computer-assisted intervention—MICCAI 2015: 18th international conference, Munich, Germany, October 5–9, 2015, proceedings, part III 18*. Springer, 2015, pp. 234–241. **1, 2**
- [6] L.-A. Tran and M.-H. Le, "Robust u-net-based road lane markings detection for autonomous driving," in *2019 International Conference on System Science and Engineering (ICSSE)*. IEEE, 2019, pp. 62–66. **1**
- [7] L.-A. Tran and D.-C. Park, "Lightweight image dehazing networks based on soft knowledge distillation," *The Visual Computer*, pp. 1–20, 2024. **1**

- [8] L.-A. Tran, S. Moon, and D.-C. Park, "A novel encoder-decoder network with guided transmission map for single image dehazing," *Procedia Computer Science*, vol. 204, pp. 682–689, 2022. 1
- [9] L.-A. Tran and D.-C. Park, "Encoder-decoder network with guided transmission map: Robustness and applicability," in *International Symposium on Intelligent Informatics*. Springer, 2022, pp. 41–54. 1, 4
- [10] —, "Encoder-decoder networks with guided transmission map for effective image dehazing," *The Visual Computer*, pp. 1–24, 2024. 1, 2, 3
- [11] K. He, J. Sun, and X. Tang, "Single image haze removal using dark channel prior," *IEEE transactions on pattern analysis and machine intelligence*, vol. 33, no. 12, pp. 2341–2353, 2010. 1, 2
- [12] H. Lee, K. Sohn, and D. Min, "Unsupervised low-light image enhancement using bright channel prior," *IEEE Signal Processing Letters*, vol. 27, pp. 251–255, 2020. 1, 3
- [13] A. M. Reza, "Realization of the contrast limited adaptive histogram equalization (clahe) for real-time image enhancement," *Journal of VLSI signal processing systems for signal, image and video technology*, vol. 38, pp. 35–44, 2004. 2
- [14] E. H. Land, "The retinex theory of color vision," *Scientific american*, vol. 237, no. 6, pp. 108–129, 1977. 2
- [15] D. J. Jobson, Z.-u. Rahman, and G. A. Woodell, "Properties and performance of a center/surround retinex," *IEEE transactions on image processing*, vol. 6, no. 3, pp. 451–462, 1997. 2
- [16] Z.-u. Rahman, D. J. Jobson, and G. A. Woodell, "Multi-scale retinex for color image enhancement," in *Proceedings of 3rd IEEE international conference on image processing*, vol. 3. IEEE, 1996, pp. 1003–1006. 2
- [17] X. Guo, Y. Li, and H. Ling, "Lime: Low-light image enhancement via illumination map estimation," *IEEE Transactions on image processing*, vol. 26, no. 2, pp. 982–993, 2016. 2
- [18] C. Wei, W. Wang, W. Yang, and J. Liu, "Deep retinex decomposition for low-light enhancement," *arXiv preprint arXiv:1808.04560*, 2018. 2, 4, 5
- [19] W. Wang, C. Wei, W. Yang, and J. Liu, "Gladnet: Low-light enhancement network with global awareness," in *2018 13th IEEE international conference on automatic face & gesture recognition (FG 2018)*. IEEE, 2018, pp. 751–755. 2, 4, 5
- [20] Y. Zhang, J. Zhang, and X. Guo, "Kindling the darkness: A practical low-light image enhancer," in *Proceedings of the 27th ACM international conference on multimedia*, 2019, pp. 1632–1640. 2, 4, 5
- [21] Y. Zhang, X. Guo, J. Ma, W. Liu, and J. Zhang, "Beyond brightening low-light images," *International Journal of Computer Vision*, vol. 129, pp. 1013–1037, 2021. 2, 4, 5
- [22] Z. Wang, X. Cun, J. Bao, W. Zhou, J. Liu, and H. Li, "Uformer: A general u-shaped transformer for image restoration," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 17 683–17 693. 2, 4
- [23] O. Özdenizci and R. Legenstein, "Restoring vision in adverse weather conditions with patch-based denoising diffusion models," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 8, pp. 10 346–10 357, 2023. 2, 4
- [24] W. Wang, H. Yang, J. Fu, and J. Liu, "Zero-reference low-light enhancement via physical quadruple priors," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2024, pp. 26 057–26 066. 2, 4, 5
- [25] K. He, J. Sun, and X. Tang, "Guided image filtering," *IEEE transactions on pattern analysis and machine intelligence*, vol. 35, no. 6, pp. 1397–1409, 2012. 3
- [26] O. Kupyn, V. Budzan, M. Mykhailych, D. Mishkin, and J. Matas, "Deblurgan: Blind motion deblurring using conditional adversarial networks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, 2018, pp. 8183–8192. 3
- [27] J. Johnson, A. Alahi, and L. Fei-Fei, "Perceptual losses for real-time style transfer and super-resolution," in *Computer Vision—ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part II 14*. Springer, 2016, pp. 694–711. 4
- [28] C. Guo, C. Li, J. Guo, C. C. Loy, J. Hou, S. Kwong, and R. Cong, "Zero-reference deep curve estimation for low-light image enhancement," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2020, pp. 1780–1789. 4
- [29] W. Yang, S. Wang, Y. Fang, Y. Wang, and J. Liu, "Band representation-based semi-supervised low-light image enhancement: Bridging the gap between signal fidelity and perceptual quality," *IEEE Transactions on Image Processing*, vol. 30, pp. 3461–3473, 2021. 4
- [30] S. W. Zamir, A. Arora, S. Khan, M. Hayat, F. S. Khan, and M.-H. Yang, "Restormer: Efficient transformer for high-resolution image restoration," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2022, pp. 5728–5739. 4
- [31] Z. Luo, F. K. Gustafsson, Z. Zhao, J. Sjölund, and T. B. Schön, "Image restoration with mean-reverting stochastic differential equations," *arXiv preprint arXiv:2301.11699*, 2023. 4
- [32] J. Zhang, J. Huang, M. Yao, Z. Yang, H. Yu, M. Zhou, and F. Zhao, "Ingredient-oriented multi-degradation learning for image restoration," in *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, 2023, pp. 5825–5835. 4
- [33] D. P. Kingma and J. Ba, "Adam: A method for stochastic optimization," *arXiv preprint arXiv:1412.6980*, 2014. 4
- [34] A. Mittal, R. Soundararajan, and A. C. Bovik, "Making a "completely blind" image quality analyzer," *IEEE Signal processing letters*, vol. 20, no. 3, pp. 209–212, 2012. 4
- [35] A. Mittal, A. K. Moorthy, and A. C. Bovik, "No-reference image quality assessment in the spatial domain," *IEEE Transactions on image processing*, vol. 21, no. 12, pp. 4695–4708, 2012. 4
- [36] L.-A. Tran and D.-C. Park, "Distilled pooling transformer encoder for efficient realistic image dehazing," *Neural Computing and Applications*, vol. 37, no. 6, pp. 5203–5221, 2025. 5